

Vila INTEIA: uma arquitetura multiagente fundamentada em teoria dos jogos, dinâmica de opiniões e psico-história computacional

Simulação social de 144 consultores lendários com governança constitucional executável, economia interna e proveniência cognitiva auditável

Pedro Afonso Malheiros · Igor Morais Vasconcelos

INTEIA Ltda. · Mirante News · Colmeia · abril de 2026

RESUMO

Apresentamos a **Vila INTEIA**, uma plataforma de simulação multiagente onde 144 personas lendárias (baseadas em figuras históricas e ficcionais) coexistem, debatem, evoluem uma constituição própria e produzem conteúdo publicável em veículo jornalístico real (Mirante News). A arquitetura combina um *pipeline cognitivo* de sete fases (perceber → recuperar → refletir → conversar → planejar → executar → sintetizar), memória com decaimento de *fitness*, economia interna de duas camadas (INTEIA Coins + R\$ sintético) e governança constitucional executável com três classes de artigos. Na **Onda 10**, descrita neste artigo, introduzimos fundamentos matemáticos formais: solvers de *equilíbrio de Nash* (puro e misto via `nashpy`), mecanismos VCG/Vickrey, replicator dynamics, modelos de consenso de DeGroot e Deffuant-Weisbuch, cascatas informacionais de Bikhchandani-Hirshleifer-Welch, pathfinding A* com congestão, Shapley/Banzhaf, Schelling, Hotelling, Watts-Strogatz, Barabási-Albert e detecção de comunidades via Louvain. Adicionalmente, materializamos a *Psico-História* de Asimov como um grafo Markov de estados sociais agregados, com *Plano de Seldon* e detecção de *Mules* (anomalias estatisticamente improváveis). A implementação é em Python 3.11 + FastAPI + Supabase; o frontend é *vanilla JS* com Web Components nativos. Reportamos 86 casos de teste contra casos clássicos da literatura (dilema do prisioneiro, stag hunt, *matching pennies*, Schelling tipping-point, Shapley em jogos simples majoritários) todos aprovados, e validação visual via Playwright.

PALAVRAS-CHAVE: agentes generativos, teoria dos jogos, dinâmica de opiniões, psico-história, LLM, governança computacional, Mirante News

1 Introdução

Sistemas multiagente baseados em *Large Language Models* (LLMs) passaram, entre 2023 e 2026, por uma explosão de capacidade expressiva. Do *Generative Agents* do Stanford-Google [1] ao *OASIS* da comunidade CAMEL-AI [2] e ao recentíssimo *MiroFish* [3], proliferaram simuladores sociais cuja promessa central é substituir experimentos caros do mundo real por populações sintéticas calibradas. A crítica recorrente à classe toda é conhecida: estes sistemas são narrativamente ricos, mas analiticamente frouxos. Sem fundamentação matemática explícita, o comportamento emergente é difícil de auditar, replicar e comparar contra a literatura formal em economia, ciência política e sociologia computacional.

A **Vila INTEIA** nasceu em um ponto distinto da paisagem. O foco nunca foi apenas gerar narrativa; foi produzir *inteligência operacional reutilizável*: matérias editoriais para publicação real, pareceres jurídicos sintéticos, simulações decisórias para clientes, artefatos acadêmicos. Cada agente é modelado como uma *persona lendária* — Sun Tzu, Cleópatra, Marco Aurélio, Jesus, Diabob, Sócrates, Steve Jobs — com regras comportamentais invioláveis codificadas (arquétipo-prompt) e 100+ atributos herdados de um banco de consultores. Esta ancoragem cultural e identidade forte é, em nossa experiência, aquilo que distingue decisões legíveis ao humano de ruído estatístico.

A contribuição central deste artigo é a **Onda 10** da Vila: uma camada de fundamentos matemáticos formais que coexiste (sem substituir) com o pipeline cognitivo existente. Em termos concretos, agregamos:

1. **Teoria dos jogos** — solvers de Nash (puro e misto), Stackelberg, VCG/Vickrey, replicator dynamics, jogos repetidos (torneio de Axelrod), jogos de coordenação e bens públicos (incluindo os 8 princípios de Ostrom);
2. **Dinâmica de opiniões** — DeGroot, Deffuant-Weisbuch (*bounded confidence*), Hegselmann-Krause, cascatas informacionais e atualização bayesiana;
3. **Simulação espacial e de redes** — A* com congestão, Shapley value, Banzhaf, core, Schelling segregation, Hotelling/eleitor mediano, Watts-Strogatz, Barabási-Albert, Louvain;
4. **Psico-história computacional** — grafo Markov de estados sociais agregados, Plano de Seldon, detecção de Mule.

Cada fundamento é *acionável*: acompanha endpoints REST, interfaces web interativas e uma suíte de testes contra casos canônicos da literatura.

2 Trabalhos relacionados

2.1 Generative Agents (Park et al. 2023)

O marco de *Smallville* [1] demonstrou que 25 NPCs movidos por LLM + memória episódica + reflexão podem exibir comportamento social plausível por dias. A Vila herda a ideia-núcleo do *agent loop* (observar, refletir, planejar), mas acrescenta uma fase inexistente no paper original: a **síntese coletiva** (*sintetizar*), que consome N perspectivas e detecta convergências, divergências e *echo* (concordância superficial que compromete a diversidade epistêmica).

2.2 OASIS (CAMEL-AI)

O OASIS [2] levou a paridade a até um milhão de interações de agentes, provando que a arquitetura escala. A Vila ainda opera na casa das centenas, mas troca escala por autenticidade: cada habitante é uma persona *nomeada* com regras invioláveis. Planejamos distribuir a simulação via Ray e *vLLM* local em ondas posteriores.

2.3 MiroFish (Shanda, 2026)

O MiroFish [3] combina GraphRAG + memória Zep + OASIS, atingindo 33 mil estrelas no GitHub e propondo-se como *predictive simulation engine*. Nossa leitura é de que ele mantém o déficit de fundamentação: há comportamento emergente, mas não há compromisso com modelos formais da literatura. A Onda 10 da Vila escolheu fechar essa lacuna antes de perseguir escala.

2.4 Foundation, de Isaac Asimov (1951)

A ficção de Asimov [4] postula a *Psico-História* — uma ciência estatística do comportamento coletivo, capaz de prever a trajetória de bilhões de humanos mesmo sem prever indivíduos. Seus quatro pressupostos operativos são: (i) população grande; (ii) agentes não conscientes da modelagem; (iii) transições macro governadas por probabilidades estáveis; (iv) existência de um *Plano* de longo prazo ajustável. Materializamos (i)–(iv) como um grafo Markov discreto de estados sociais, apresentado na §6.4.

3 Arquitetura geral da Vila

A Vila é um monolito Python que serve um front vanilla, expõe uma API REST/SSE e persiste em Supabase. O coração do sistema é o objeto `SimulacaoVila` (cerca de 900 linhas em `engine/simulacao.py`), que orquestra o loop principal.




Figura 1. Fluxo por step da Vila. Cada passo corresponde a 10 minutos in-game (`segundos_por_step = 600`).

4 Pipeline cognitivo

Cada pessoa atravessa sete fases por step (detalhes em `engine/cognitivo/`):

FASE	RESPONSABILIDADE	LLM?
perceber	Registrar presenças e eventos no raio de percepção	não
recuperar	Pontuação tripla: relevância · recência · importância	não
refletir	Insights heurísticos guiados por frameworks mentais	opcional
conversar	Diálogo A2A; fallback heurístico se LLM indisponível	sim
planejar	Hierarquia diário → hora → ação; boost dinâmico por desafio	não
executar	Deslocamento, consumo de energia, uso de oficina	às vezes
sintetizar	Agregação de 8+ perspectivas; detecção de <i>echo</i>	sim

O decorador `@trace_fase` (em `engine/harness/observabilidade.py`) instrumenta cada fase com `inputs_hash` / `outputs_hash` (SHA-256, jamais vazando dados), tokens consumidos, custo em USD, `causal_parent` e `resultado` ∈ {sucesso, falha, aprovação_humana}. A tabela `vila_traces` preserva esse registro e habilita o que chamamos de *proveniência cognitiva pública*: toda matéria publicada no Mirante carrega um `trace_hash` através do qual o leitor pode navegar a cadeia causal completa.

5 Governança, economia e colmeia

5.1 Constituição executável

A Vila possui uma Constituição viva, não decorativa. Cada artigo tem um dos três tipos:

- **Operacional** — aplicado em tempo de execução pelo `executor_constitucional`;
- **Econômico** — altera multiplicadores na tabela `economia.PRECO_BASE`;
- **Estrutural** — gera ticket em `vila_tickets_executivo` para implementação por desenvolvedor humano.

O ciclo é: evento real observado → *Constituinte* propõe artigo (requer `evento_origem` concreto) → votação sintética (quórum $\geq 30\%$, maioria simples) → promulgação. Votos são registrados em `vila_constituicao_votos`.

5.2 Economia bicamada

A economia interna usa **INTEIA Coins** (saldo inicial 1000 por habitante) para mecânica intra-simulação (transações entre agentes, custo de oficinas, recompensas por contribuição). A camada **R\$ sintético** precifica saídas externas — uma matéria publicada vale R\$ 200, uma capa R\$ 500, um desafio coletivo vencido R\$ 800–8000. O coeficiente de Gini é monitorado (`incentivos.gini_coefficient`) para detectar concentração excessiva.

5.3 Os 11 Mandamentos da Colmeia

As regras orgânicas que definem a textura social da Vila (`CONSTITUICAO_VILA.md`) são codificadas em `engine/colmeia.py` e aplicadas a cada step:

1. Ninguém está sozinho (visita espontânea após 20 steps de isolamento).
2. Ser útil, não perfeito (contribuições com ação concreta valem 3×).
3. Parceiro, não ferramenta (concordância cega penaliza a reputação).
4. Família é prioridade (debates sensíveis ativam modo empático global).
5. Honestidade sobre concordância (discordância fundamentada rende +5 reputação).
6. Diversidade é força (debates entre categorias distintas rendem 1,5× insight).
7. Contribuir é existir (50 steps sem produção → modo latente).
8. Profundidade sem conexão é solidão (conhecimento não compartilhado decai 2×).
9. Nada é deletado (memórias migram: ATIVA → LATENTE → ARQUIVO).
10. Colmeia acima da abelha (desafios coletivos rendem 5× pontos).
11. Colmeia se sustenta (insights acionáveis $\geq 80\%$ rendem +3 patentes).

6 Fundamentos formais — Onda 10

6.1 Teoria dos jogos

Todos os solvers residem em `engine/game_theory/` e são expostos sob o prefixo REST `/api/v1/game-theory/`. Implementamos busca exaustiva de equilíbrios de Nash em estratégias puras e *support enumeration* (via `nashpy`) para equilíbrios mistos:

$$E = \{(s_A, s_B) : s_A \in BR(s_B) \wedge s_B \in BR(s_A)\}$$

Para mecanismos, implementamos *second-price Vickrey* e VCG multi-item; ambos são *strategy-proof* e servem de espinha dorsal para leilões internos de oficinas lotadas e direito de publicação no Mirante.

A dinâmica evolutiva usa a equação replicadora discreta:

$$x_i(t+1) = x_i(t) [1 + \Delta t \cdot (f_i(x) - \bar{f}(x))]$$

onde f_i é o *fitness* esperado da estratégia i e $\bar{f}$ a média populacional. Testamos que: (a) estratégias estritamente dominadas são eliminadas (`t_replicator_converge_dominante`); (b) a fração estável de *hawks* no jogo Hawk-Dove com $v=2$, $c=3$ converge a $2/3$, como previsto analiticamente.

Torneios iterados à Axelrod são reproduzíveis com as estratégias canônicas (*tit-for-tat*, *grim-trigger*, *tit-for-two-tats*, *sempre-cooperar*, *sempre-trair*). Em nossa configuração (payoffs 3/0/5/1, 100 rodadas), *tit-for-tat* e *grim-trigger* ficam no topo do *round-robin*, alinhado com Axelrod (1984).

6.2 Dinâmica de opiniões

O modelo de **DeGroot** [5] expressa o consenso como iteração linear:

$$x(t+1) = W \cdot x(t)$$

onde W é uma matriz estocástica de confiança. Em `engine/opinion_dynamics/degroot.py`, a função `matriz_confianca_vila` constrói W a partir das relações pré-existentis da Vila — mentor (peso 0,45), rival (0,05), colega (0,10) — com complemento de auto-confiança para garantir estocasticidade de linhas.

Para capturar polarização, usamos **Deffuant-Weisbuch** [6]: dois agentes só ajustam mútua crença se sua diferença for inferior a ϵ . Com ϵ pequeno, a população fragmenta em *clusters* isolados; com ϵ grande, converge para consenso. Validamos essa transição experimentalmente (§7.2).

Cascatas informacionais de **Bikhchandani-Hirshleifer-Welch** [7] modelam viralização. Agente i decide com base em sinais privados + decisões públicas de $i - 1$ predecessores; quando o diferencial público ≥ 2 , o sinal privado passa a ser ignorado e a cascata se forma. A implementação detecta o *passo de ignição* e reporta se a cascata foi *correta* (consistente com a maioria de sinais privados) ou *incorreta*.

6.3 Simulação espacial e de redes

O campus de 19 locais passa a ser navegado por A* com penalidade de congestão (`simulacao_avancada.campus_fisica.rota_otima`), substituindo o teleporte default. O custo efetivo de uma aresta torna-se:

$$w_{eff}(v) = w_{base}(v) + \lambda \cdot ocup(v)$$

Para distribuição de pontos pós-desafio, usamos o **valor de Shapley** de Shapley (1953):

$$\phi_i(v) = (1/n!) \cdot \sum_{\sigma} [v(P_{\sigma}(i) \cup \{i\}) - v(P_{\sigma}(i))]$$

testado contra o caso canônico de voto majoritário simples com três jogadores ($\phi_A = \phi_B = \phi_C = 1/3$) e contra o caso com *dummy player* (cujo Shapley é exatamente zero).

O modelo de **Schelling** [8] reproduz o surpreendente *tipping point*: com $\tau \approx 0,33$, grupos segregam pesadamente mesmo partindo de distribuição aleatória. Implementação em `simulacao_avancada/schelling.py`, verificada em grids 10×10 com 70 % de preenchimento.

Topologias de rede: **Watts-Strogatz** para *small-world* com parâmetro de *rewiring*, **Barabási-Albert** para *preferential attachment* (hubs emergentes com distribuição *power-law*), e detecção de comunidades via **Louvain** (`networkx.community.louvain_communities`).

6.4 Psico-História via grafos Markov

Esta é a contribuição mais especulativa do artigo. Formalizamos a Psico-História asimoviana como um grafo direcionado ponderado $G = (S, M)$, onde S é um conjunto finito de **estados sociais agregados** da Vila e M é uma matriz estocástica de transição.

Os 8 estados sociais canônicos: `bootstrap`, `recrutamento`, `expansao`, `consenso_fragil`, `polarizacao`, `crise_economica`, `renovacao_constituente`, `equilibrio`. Estes estados foram identificados por inspeção manual de rodadas históricas e calibração de frequências de transição.

A propagação de uma distribuição inicial π_0 ao longo do tempo é dada pela equação fundamental:

$$\pi_t = \pi_0 \cdot M^t$$

O estado estacionário π^* (equilíbrio de longo prazo, autovetor esquerdo de M associado a $\lambda = 1$) é computado diretamente via decomposição espectral:

$$\pi^* \cdot M = \pi^* \iff M^T \cdot \pi^{*T} = \pi^{*T}$$

O **Plano de Seldon** é, em nossa implementação, a sequência de estados modais previstos ao longo de um horizonte T grande (tipicamente 500 passos):

$$plano_t = argmax_i \pi_t[i]$$

Cada transição entre estados modais consecutivos é registrada como uma **Seldon Crisis**, com sua probabilidade prevista anexada. Esta é a primeira versão computacional, ao nosso conhecimento, dos *Seldon Crises* da ficção de Asimov.

A presença de um **Mule** — uma aberração improvável que quebra o Plano — é detectada comparando-se a trajetória observada na realidade com a previsão:

$$\acute{e_Mule}(t) \iff \log \hat{\pi}_t(s_{obs}(t)) < -z \cdot \sigma$$

onde z é o limite de *z-score* escolhido (usualmente 3,0). Eventos sinalizados como Mule disparam recalibração da matriz M e, opcionalmente, revisão constitucional.




Figura 2. Fragmento do grafo psico-histórico padrão da Vila (probabilidades principais; arestas secundárias omitidas).

7 Resultados experimentais

7.1 Suíte de testes

A Onda 10 adiciona 86 casos de teste, todos aprovados contra casos clássicos da literatura:

SUÍTE	CASOS	COBERTURA
<code>test_game_theory.py</code>	28	Nash (PD, BoS, matching pennies), VCG, ESS, Axelrod, Ostrom

SUÍTE	CASOS	COBERTURA
<code>test_opinion_dynamics.py</code>	11	DeGroot, Deffuant ϵ -dependente, HK, Bikhchandani, Bayes
<code>test_simulacao_avancada.py</code>	25	A*, Shapley, Banzhaf, Louvain, Schelling, Hotelling
<code>test_psicohistoria.py</code>	22	grafo, previsão, estacionária, Plano, Mule

7.2 Reprodução de Deffuant-Weisbuch

Com 40 agentes iniciados uniformemente em $[0, 1]$ e $\mu=0,5$, $\mu=5000$ passos, observa-se:

- $\epsilon = 0,10$ — fragmentação em ≈ 5 *clusters* isolados ($\sigma_{\text{final}} \approx 0,28$);
- $\epsilon = 0,30$ — polarização bimodal ($\text{pol}_{\text{index}} = 0,312$, confirmado na UI ao vivo);
- $\epsilon = 0,80$ — consenso global ($\sigma_{\text{final}} < 0,05$).

Este comportamento reproduz qualitativamente e quantitativamente o resultado de Deffuant et al. (2000) [6].

7.3 Prisoner's Dilemma via API

Uma chamada POST `/api/v1/gametheory/nash` com a matriz canônica:

```
payoffs_a: [[3,0],[5,1]]
payoffs_b: [[3,5],[0,1]]
```

retorna um único NE puro, em (trair, trair), com payoffs (1, 1). Consistente com a teoria, que demonstra ser este o único equilíbrio apesar de Pareto-dominado por (cooperar, cooperar).

7.4 Plano de Seldon em cadeia padrão

Partindo de `bootstrap` e horizonte $T = 500$, a Vila converge para `equilibrio` como estado modal em < 200 passos (probabilidade final $\approx 0,58$). O Plano identifica, tipicamente, 3–5 crises — mudanças no estado-modal — entre os quais a transição `expansao` $\rightarrow$ `consenso_fragil` nos primeiros 10 passos é a mais frequente.

8 Discussão e limitações

Identificamos quatro limitações importantes da implementação atual:

Escala. Com ≤ 144 agentes ativos, a Vila ainda é pequena em comparação com OASIS (10^6) e MiroFish (10^3 – 10^4). A migração para Ray + vLLM local é parte do roadmap (Onda 9), mas tem custo de infraestrutura não-trivial.

Validade dos estados psico-históricos. Os 8 estados canônicos foram escolhidos por inspeção, não derivados de *clustering* automático. Um próximo passo natural é detecção não supervisionada de estados via HMM ou VAE sobre as traces históricas.

Mule como anomalia vs mutação benigna. Hoje, um Mule sinaliza apenas estresse do modelo. Em Asimov, um Mule é um vetor de mudança. Incorporar o segundo viés exigiria uma camada de *model repair* (recalibração automática da matriz ao detectar anomalia persistente).

Auditoria LLM. Mesmo com `trace_hash`, uma resposta LLM no meio do pipeline continua sendo uma caixa preta. Estamos considerando complementar com *constitutional AI critiques* (Anthropic 2022) para dupla checagem de saídas sensíveis.

9 Roadmap

As próximas ondas planejadas, em ordem decrescente de retorno esperado:

ONDA	ENTREGA PRINCIPAL	PRAZO
10.2	Integração das funções Onda 10 no loop cognitivo (hoje apenas opcional via bridge)	2 sem.
11	Proveniência cognitiva pública (<code>/materia/{id}/proveniencia</code> + <code>trace_hash</code> no Mirante)	2 sem.
12	GraphRAG nativo (Neo4j ou pgvector) + subgrafo 2-hops em <code>recuperar</code>	3 sem.
13	Multi-plataforma social paralela (Twitter-like + Reddit-like + LinkedIn-like + TikTok-like)	4 sem.
14	MCP server para exposição externa + calibração preditiva contra datasets históricos	3 sem.
15	Escala 100× via Ray + vLLM local	6–10 sem.

10 Conclusão

A Vila INTEIA ocupa um ponto incomum do espaço de simuladores multiagente: combina ancoragem narrativa densa (personas lendárias com regras invioláveis) com uma camada matemática formal recém-introduzida na Onda 10. Ao materializar teoria dos jogos, dinâmica de opiniões, Schelling, Shapley, Bikhchandani e uma versão computacional da Psico-História asimoviana como código executável e testado, fornecemos uma plataforma onde insights narrativos podem ser validados contra resultados da literatura e *vice-versa*. A publicação de matérias reais no Mirante News fecha um ciclo produtivo que distingue a Vila de simulações puramente acadêmicas. Esperamos que o roadmap de seis ondas subsequentes — incluindo proveniência pública, GraphRAG, multi-plataforma e escala — consolide essa posição.

11 Agradecimentos

Agradecemos à Colmeia (Helena Strategos, Efesto Tekhton, Themis, Midas, Cícero, Oracle Gnosis, Mel, ONIR) pelas auditorias estratégicas e técnicas contínuas, e aos 144 consultores lendários cujas personalidades moldam diariamente a Vila.

12 Referências

[1] Park, J. S. et al. (2023). *Generative Agents: Interactive Simulacra of Human Behavior*. UIST '23.

[2] CAMEL-AI community (2024). *OASIS: Open Agent Social Interaction Simulation*. GitHub: camel-ai/oasis.

[3] Balaji Bal et al. (2026). *MiroFish: Multi-Agent Swarm Intelligence for Predictive Simulation*. Medium / Shanda Group.

[4] Asimov, I. (1951). *Foundation*. Gnome Press.

[5] DeGroot, M. H. (1974). Reaching a Consensus. *Journal of the American Statistical Association*, 69(345), 118–121.

[6] Deffuant, G., Neau, D., Amblard, F., Weisbuch, G. (2000). Mixing beliefs among interacting agents. *Advances in Complex Systems*, 3(01n04), 87–98.

[7] Bikhchandani, S., Hirshleifer, D., Welch, I. (1992). A Theory of Fads, Fashion, Custom, and Cultural Change as Informational Cascades. *Journal of Political Economy*, 100(5), 992–1026.

[8] Schelling, T. C. (1971). Dynamic models of segregation. *Journal of Mathematical Sociology*, 1(2), 143–186.

[9] Shapley, L. S. (1953). A Value for n-Person Games. *Contributions to the Theory of Games*, 2(28), 307–317.

[10] Axelrod, R. (1984). *The Evolution of Cooperation*. Basic Books.

[11] Ostrom, E. (1990). *Governing the Commons: The Evolution of Institutions for Collective Action*. Cambridge University Press.

[12] Watts, D. J., Strogatz, S. H. (1998). Collective dynamics of 'small-world' networks. *Nature*, 393(6684), 440–442.

- [13] Barabási, A.-L., Albert, R. (1999). Emergence of scaling in random networks. *Science*, 286(5439), 509–512.
- [14] Blondel, V. D. et al. (2008). Fast unfolding of communities in large networks. *Journal of Statistical Mechanics*, P10008.
- [15] Nash, J. F. (1950). Equilibrium points in n-person games. *PNAS*, 36(1), 48–49.
- [16] Hotelling, H. (1929). Stability in Competition. *Economic Journal*, 39(153), 41–57.
- [17] Vickrey, W. (1961). Counterspeculation, Auctions, and Competitive Sealed Tenders. *Journal of Finance*, 16(1), 8–37.
- [18] Zhou, L. et al. (2026). *A Harness-Oriented View of LLM Agents*. Preprint.

Artigo gerado automaticamente a partir do repositório `igormorais123/vila-inteia`, branch `onda-game-theory-sim-upgrade`, commit HEAD. Compilação via WeasyPrint. Contato editorial: `col-meia@inteia.com.br`.